Szybkie grupowanie opisów binarnych metodą CLASSIX

Protokół badawczy i opis projektu

Ivan Kovalov
Politechnika Opolska, Wydział Informatyki
Przedmiot: Rozpoznawanie wzorców, grupa 2
Projekt indywidualny

5 listopada 2026 r.

Streszczenie

Celem projektu jest zbadanie, jak liczba obiektów oraz stopień rozmycia grup wpływają na koszt obliczeniowy i jakość grupowania binarnych opisów danych. Główną analizowaną metodą jest CLASSIX w wariancie wykorzystującym odległość Tanimoto (CLASSIX_T), porównywany z algorytmem DBSCAN przy tej samej definicji odległości. Badanie zostanie przeprowadzone na syntetycznych danych binarnych generowanych na podstawie wektorów bazowych i losowego odwracania bitów. Obejmie pomniejszoną adaptację eksperymentu z sekcji 5.1 publikacji Güttela i Roya oraz eksperyment własny ze zmiennym prawdopodobieństwem odwracania bitów. Jakość grupowania będzie oceniana za pomocą Adjusted Rand Index (ARI), liczby wykrytych klastrów i udziału szumu, a koszt – przede wszystkim przez czas wykonania.

1 Dane projektu

Temat	Szybkie grupowanie opisów binarnych metodą CLASSIX
Autor	Ivan Kovalov
Współautorzy	Brak – projekt indywidualny
Uczelnia i wydział	Politechnika Opolska, Wydział Informatyki
Prowadzący	mgr inż. Michał Wierzbicki
Przedmiot / grupa	Rozpoznawanie wzorców, grupa 2
Repozytorium projektu	https://github.com/kovalov89/rozpoznawanie_wzorow26-27

2 Cel i opis zadania

Pytanie badawcze brzmi: *Jak zmieniają się koszt i jakość grupowania opisów binarnych wraz z liczbą obiektów oraz rozmyciem grup?* Zadanie obejmuje wyjaśnienie reprezentacji binarnej, odległości Tanimoto oraz dwóch faz CLASSIX: agregacji obiektów wokół punktów początkowych i łączenia utworzonych grup. Należy również przedstawić regułę wczesnego odrzucania kandydatów właściwą dla odległości Tanimoto, sprawdzić dostępność implementacji i przygotować mały zbiór demonstracyjny. Zbiór demonstracyjny obejmuje 3 klastry, 16 cech i 18 obiektów (wektor bazowy oraz 5 obiektów pochodnych na klaster), z ziarnem generatora 42. Jest to pomniejszona demonstracja sposobu generowania danych, a nie pełne odtworzenie eksperymentów z publikacji.

3 Protokół badawczy

1. **Generowanie danych do eksperymentu głównego.** Zostaną utworzone 10 klastrów syntetycznych opisanych wektorami binarnymi o wymiarze $d = 256$. Dla każdego klastra generator losuje wektor bazowy x_i. Następnie tworzy obiekty pochodne przez niezależne odwracanie każdego bitu z prawdopodobieństwem

$$p_i = 0{,}1 \cdot \frac{\|x_i\|_1}{d},$$

gdzie $\|x_i\|_1$ jest liczbą jedynek w wektorze bazowym. Przygotowane zostaną zbiory o liczebności 400, 800 i 1600 obiektów. Dla zachowania dokładnej liczebności każdy klaster będzie zawierał odpowiednio 40, 80 lub 160 obiektów łącznie z wektorem bazowym. Wektory bazowe, prawdopodobieństwa p_i, etykiety klastrów i ziarna losowe zostaną zapisane. Względem publikacji zmniejszono liczebność danych i wymiar do 256 cech; jest to jawnie oznaczona adaptacja generatora i eksperymentu.

2. **Eksperyment własny – rozmycie grup.** Dla $n = 800$ i $d = 256$ zostaną przygotowane trzy poziomy odwracania bitów, określone przez mnożniki $\lambda \in \{0{,}5; 1; 2\}$ bazowego prawdopodobieństwa: $p_i^{(\lambda)} = \lambda p_i$. Większy mnożnik oznacza większe rozproszenie obiektów wokół wektorów bazowych. Poziomy te są własnym rozszerzeniem badania.

3. **Porównywane metody i parametry.** CLASSIX_T zostanie porównany z DBSCAN. Obie metody otrzymają identyczne dane i będą korzystać z odległości Tanimoto. Jako punkt wyjścia przyjęte zostaną wartości z sekcji 5.1 publikacji: `radius` $= 0{,}4$, `minPts` $= 5$ dla CLASSIX_T oraz `eps` $= 0{,}4$, `min_samples` $= 5$ dla DBSCAN. Przed właściwymi pomiarami zostanie sprawdzona zgodność znaczenia parametrów z użytymi implementacjami; parametry zostaną następnie utrwalone w protokole.

4. **Metryki jakości i kosztu.** Dla każdego uruchomienia zostaną zapisane: czas wykonania, Adjusted Rand Index (ARI) względem etykiet generatora, liczba wykrytych klastrów oraz udział obiektów oznaczonych jako szum. Etykiety generatora posłużą wyłącznie do oceny jakości, a nie jako wejście algorytmów.

5. **Powtarzalność i kontrola pomiaru.** Zaplanowano pięć losowań z ziarnami 42–46. Obie metody będą testowane na tych samych realizacjach danych i w tym samym środowisku CPU. Zostaną zachowane parametry, wersje bibliotek, wektory bazowe, wyniki wszystkich uruchomień oraz błędy i przyczyny brakujących wyników. Wyniki zostaną przedstawione jako średnia i odchylenie standardowe. Jeżeli DBSCAN będzie wymagał wcześniejszego przygotowania macierzy odległości, czas jej obliczenia zostanie wliczony do czasu całkowitego; dodatkowo można podać sam czas grupowania. W porównaniu należy oddzielić wpływ algorytmu od różnic implementacyjnych. Dla wektorów zerowych zostanie jawnie przyjęta konwencja $d_T(0, 0) = 0$ oraz $d_T(0, b) = 1$ dla $b \neq 0$; zgodność tej konwencji w obu implementacjach zostanie sprawdzona.

4 Repozytorium i harmonogram checkpointów

Repozytorium projektu:
https://github.com/kovalov89/rozpoznawanie_wzorow26-27

Repozytorium wykorzystanej implementacji CLASSIX:
https://github.com/kaustubhroy1995/classix_tanimoto_manhattan

Etap	Zakres checkpointu	Termin
C1	Prezentacja tematu, protokół badawczy i mały zbiór demonstracyjny	30.11.2026
C2	Generator oraz przygotowanie zbiorów 400, 800 i 1600 obiektów; test implementacji	17.12.2026
C3	Porównanie CLASSIX_T i DBSCAN, analiza metryk i wnioski z eksperymentów	14.01.2027

Literatura

[1] S. Güttel, K. Roy, *Fast and explainable clustering in the Manhattan and Tanimoto distance*, arXiv:2601.08781, 2026. Dostęp: https://arxiv.org/abs/2601.08781.

[2] K. Roy, *classix_tanimoto_manhattan* [repozytorium kodu], GitHub. Dostęp: https://github.com/kaustubhroy1995/classix_tanimoto_manhattan.